Есть ли смысл спорить?

Объяснение статьи Никиты Шляпочника простыми словами

(для тех, кто не логик и не хочет им становиться)

О чём вообще эта статья, в одном абзаце

Люди тратят кучу времени и нервов на споры. Некоторые споры действительно безнадёжны: стороны хотят несовместимых вещей. Но очень многие споры — пустышки: люди вкладывают в одно и то же слово *разный смысл* и на самом деле говорят о разном. Статья строит математический «прибор», который для конкретного спора отвечает на четыре вопроса: **(1)** придут ли стороны к согласию, если продолжат обмениваться доводами; **(2)** если нет — какой *минимальный* набор убеждений мешает согласию; **(3)** этот конфликт настоящий или это спор о словах; **(4)** сколько времени займёт схождение. И главное: вопрос №3 можно решить *одной быстрой проверкой на компьютере*, а не бесконечным разбором полётов.

Пример из жизни

Классика: «Если в лесу упало дерево и никто не слышал — был ли звук?» Спор может длиться часами, пока стороны не поймут: один под «звуком» имеет в виду *колебания воздуха* (тогда да, был), а другой — *услышанное ощущение* (тогда нет). Это *спор о словах*: разногласие исчезает, как только слово «звук» расщепляют на два разных. Статья учит отличать такие споры от настоящих — автоматически.

1. Базовые понятия: как математика видит спор

Чтобы рассуждать строго, надо перевести «мнения» и «доводы» на язык математики. Вот весь необходимый словарик.

Позиция (теория)

Мнение человека — это набор утверждений, в которые он верит, *вместе со всеми следствиями* из них. Если ты веришь «все кошки — животные» и «Мурка — кошка», ты автоматически веришь и «Мурка — животное», даже если никогда не произносил этого вслух. Такой «набор убеждений, замкнутый по выводам», в статье называется **теорией**.

Оператор следствия Cn

Это машинка «выведи всё, что следует». Даёшь ей набор утверждений A — она возвращает $\mathrm{Cn}(A)$: сам набор плюс все его логические следствия. Три естественных свойства: (1) исходные утверждения остаются внутри; (2) если знаешь больше — выводишь не меньше; (3) повторный запуск ничего не добавляет (всё уже выведено). Это аксиомы Тарского — фундамент всей статьи.

Противоречие и совместимость

Набор убеждений **противоречив**, если из него выводится и «φ», и «не φ» одновременно — тогда формально из него выводится вообще всё что угодно (логики называют это «взрывом»). Два человека **совместимы**, если объединение их убеждений непротиворечиво: их взгляды можно склеить в одну непротиворечивую картину мира.

Несовместное ядро (MUS)

Если объединить убеждения спорщиков и получить противоречие, можно найти *минимальный виновный набор*: несколько утверждений, которые вместе несовместимы, но убери любое одно — и противоречие исчезает. Это и есть **ядро спора** (по-английски MUS — minimal unsatisfiable subset). Ядер может быть несколько. Ядро — это точный ответ на вопрос «из-за чего именно мы спорим», очищенный от всего лишнего.

Пример из жизни

Аня: «Поедем в отпуск только к морю». Борис: «Только в горы». Плюс общее убеждение: «Отпуск один, и он либо у моря, либо в горах, но не там и там». Эти три утверждения вместе несовместимы — это ядро. А вот их общая вера в то, что «отпуск нужен», в ядро не

входит: она конфликту не мешает. Ядро отделяет *предмет* спора от всего, в чём стороны согласны.

2. Вопрос 1: сойдётся ли спор?

Как моделируется обмен доводами

Представим группу из n человек. Между ними — «граф общения»: стрелка от u к v значит «v слышит u». В каждом раунде человек слушает соседей и *присоединяет* к своим убеждениям всё услышанное — но только от той максимальной группы людей, с которой это не создаёт противоречия (нельзя же одновременно поверить в «φ» и «не φ»). Важно: в этой модели люди *не отказываются* от своих убеждений, а только накапливают новые. Это модель честного обмена доводами, а не переубеждения.

Результат 1: критерий сходимости

Согласие достижимо **тогда и только тогда**, когда убеждения *всех* участников можно склеить в одну непротиворечивую картину. Причём проверять надо всех *вместе*, а не по парам!

Почему «по парам» недостаточно — самый поучительный пример статьи:

Пример из жизни

Три друга выбирают пиццу. Аня: «Возьмём пепперони или грибную» ($p \vee q$). Борис: «Только не пепперони» ($\neg p$). Вика: «Только не грибную» ($\neg q$). Любые *двое* из них легко договорятся: Аня с Борисом возьмут грибную, Аня с Викой — пепперони, Борис с Викой вообще не конфликтуют. Но *втроём* они несовместимы: из трёх утверждений вместе следует противоречие. Попарного мира недостаточно — нужен общий.

Если общая картина существует, то при разумной связности графа общения (любой довод рано или поздно может дойти до любого человека) все сойдутся к одному и тому же итоговому мнению — объединению всех стартовых убеждений — не позже чем за $(n-1)B$ раундов, где B — «за сколько раундов граф гарантированно связывает всех». Интуиция доказательства красивая: каждый исходный довод *затапливает* сеть, как вода, переходя за каждое «окно связности» хотя бы к одному новому человеку.

3. Вопрос 1½: а может спор колебаться вечно?

Нет. И это, пожалуй, самый неожиданный технический результат.

Результат 2: спор всегда останавливается

Из *любого* начального положения, при *любой* последовательности графов общения и *любых* правилах выбора (даже если их подбирает злонамеренный противник) динамика замирает не более чем за $n(n-1)$ «раундов с изменениями». Колебания — когда мнения ходят по кругу — **невозможны в принципе**.

Идея доказательства: убеждения каждого человека могут только расти, а «строк роста» у каждого не больше $n-1$ — потому что любое достижимое мнение оказывается объединением стартовых мнений какой-то *коалиции* участников, а коалиция может расширяться максимум $n-1$ раз. Практический смысл: если спор «завис» — он не «ещё идёт», он *уже раскололся* на устойчивые лагеря. Группа распадается на кластеры: внутри кластера мнения одинаковы, между кластерами — несовместимость.

4. Вопрос 3 (главный): спор о деле или спор о словах?

Это центральная новизна статьи. До сих пор мы молчаливо считали, что все понимают слова одинаково. Снимем это допущение.

Заякоренный словарь A

Это список терминов, значение которых стороны *реально* считают общим и договорились не оспаривать: согласованный глоссарий, раздел «Определения» в договоре, утверждённые метрики компании. Всё остальное — слова, которые каждый мог понимать по-своему. Важно: якорь — это *вход* модели (стороны задают его сами), а не то, что модель вычисляет.

Вербальный vs субстантивный спор

Спор **вербальный** (о словах), если существует «перевод» незаякоренных терминов одной стороны — расщепление многозначных слов на разные смыслы, — после которого противоречие исчезает. Спор **субстантивный** (о деле), если

никакой перевод не помогает: конфликт сидит в самих заякоренных терминах.

Зачем нужен якорь? Без него критерий вырождается: можно переименовать *все* слова оппонента в новые — и любой спор, даже «p против не-p», станет «вербальным». Вся содержательность держится на запрете трогать якорь.

Результат 3: анкер-критерий — одна проверка вместо перебора

Не нужно перебирать все мыслимые переводы (их бесконечно много). Достаточно одного, самого радикального: **максимальной дизамбигуации** — переименовать все незаякоренные слова одной стороны в заведомо новые. Тогда:

- если после этого противоречие исчезло — спор *вербальный*;
- если осталось — спор *субстантивный*, и тогда обязательно найдётся конкретная формула φ *только из заякоренных слов*, в которую одна сторона верит, а другая верит в её отрицание. Вот он, настоящий предмет спора, предъявленный явно.

На компьютере это один вызов SAT-решателя (программы проверки выполнимости) — секунды, а не часы.

Доказательство опирается на классическую теорему логики — *интерполяцию Крейга*: если из X следует «не Y», то между ними найдётся «формула-посредник» только из их *общих* слов. После полного переименования общие слова — это ровно якорь, поэтому конфликт, если он выжил, обязан жить на якоре.

Дополнительно доказана **симметричность**: неважно, чей словарь переводить — Ани, Бориса или обоих — вердикт один и тот же. Процедура никого не назначает «виноватым в путанице».

Пример из жизни

Вербальный: спор про дерево и звук — расщепляем «звук» на «звук-колебания» и «звук-ощущение», противоречие исчезает.
Вербальный (почти): «хот-дог — это бутерброд?» — зависит от того, что значит «бутерброд».
Субстантивный: «снизила ли вакцина смертность?» — если «вакцина», «смертность» и данные в якоре, никакая игра словами

конфликт не снимет: спор о фактах.
Смешанный (самый частый): перевод снимает большую часть конфликта, но остаётся малое настоящее ядро. Ценность метода именно в этом: показать сторонам «вы согласны на 90%, а спорите на самом деле вот об этом».

5. Вопрос 2: как разблокировать безнадёжный спор?

Если спор субстантивный, согласие невозможно *без пересмотра убеждений*. Чем пожертвовать?

Результат 4: прейскурант уступок

Набор уступок H разблокирует спор тогда и только тогда, когда H задевает **каждое** несовместное ядро хотя бы по одному утверждению («пробивающее множество»). Минимальная уступка = минимальное пробивающее множество. Найти самое дешёвое — вычислительно трудная задача (NP-трудная), но при небольшом числе ядер решается перебором, а компромисс между «сколько уступить» и «сколько считать» даёт MaxSAT-решатель.

Пример из жизни

Представь три ядра-конфликта как три запертых двери, каждая на нескольких замках-убеждениях. Чтобы пройти, нужно открыть *каждую* дверь, сняв хотя бы один замок с каждой. Если один замок висит сразу на двух дверях — снять его выгоднее всего. Поиск самого дешёвого набора «замков» — это и есть минимальная уступка.

Приятный бонус (лемма о монотонности): честное расщепление смыслов слов *никогда не увеличивает* массу конфликта — переводом нельзя случайно сделать спор хуже.

6. Вопрос 4: сколько ждать?

Для «идеальных» спорщиков (мгновенно выводят все следствия) время до согласия не превосходит диаметра графа общения — наибольшего

расстояния между двумя людьми в сети. Для реалистичных, «медленных» спорщиков, которые делают один шаг вывода за раунд:

$$R \leq \underbrace{\operatorname{diam}(G)}_{\text{доводы доходят до всех}} + \underbrace{d_{\vdash}}_{\text{каждый додумывает следствия}}$$

Сначала сами *посылки* затапливают сеть (это $\operatorname{diam}(G)$ раундов), потом каждый локально довыводит следствия глубины $d_{\vdash}$. Оценки *складываются*, а не перемножаются — в статье честно отмечено, что в ранней версии тут была ошибка.

7. Стоит ли вообще спорить? Экономика

Пусть согласие принесёт пользу B, каждый раунд спора стоит c, всего раундов не больше R, а с вероятностью π спор окажется вербальным (то есть разрешимым после согласования слов).

Результат 5: правило рациональной остановки

- Если ядро заведомо субстантивное — **прекращай спор немедленно**: пользы ноль, издержки капают.
- Спорить «вслепую» разумно только при $\pi B \geq cR$: шанс на разрешимость, умноженный на выигрыш, должен покрывать стоимость раундов.
- Анкер-тест перед спором имеет измеримую **ценность информации**: $\mathrm{VoI} = \min\{\, cR(1-\pi),\ \pi(B - cR) \,\}$. Если тест стоит дешевле — сначала тестируй, потом спорь. Это перенос классической теории ценности информации (Говард, 1966) на споры.

Интуиция: тест спасает либо от бесполезного спора (если вердикт «субстантивный»), либо даёт уверенность вступить в спор, в который вслепую вступать было невыгодно.

8. Важная оговорка: согласие — не истина

Если группа сошлась — это значит лишь, что их *стартовые* убеждения были совместимы, и они склеились в общую картину. Модель ничего не говорит о том, *верна* ли эта картина: группа единомышленников дружно

сойдётся и на ошибке. Предел спора зависит от того, с чем люди в него вошли, а не от устройства мира.

9. Что здесь ново, а что — аккуратная сборка известного

Автор честно разделяет. Результаты о сходимости, стабилизации и ядрах — грамотная сборка зрелых инструментов (модели динамики мнений, слияние убеждений, MUS-анализ, теория диагностики Рейтера). **Заявка на новизну — вопрос №3**: философское различение «спора о словах» и «спора о деле» (восходящее к Чалмерсу, 2011) впервые превращено в *алгоритм*: связка «ядро спора $\times$ перевод словаря относительно якоря $\times$ одна SAT-проверка $\times$ динамика мнений». И это *доказуемо дёшево*: одна проверка вместо перечисления всех ядер, которых в худшем случае экспоненциально много.

10. Честные ограничения

- Якорь A модель не находит — его задают стороны. Где согласованного словаря нет, метод не взлетает. (Автоматическое извлечение якоря — главное будущее направление.)
- Люди идеализированы: не лгут, не хитрят, не отказываются от убеждений, только накапливают.
- Согласие $\neq$ истина (см. выше).
- Численные эксперименты — иллюстрации доказанных теорем на синтетических данных, а не проверка на реальных дебатах.

Итог одним абзацем

Статья превращает спор из риторики в объект с проверяемой структурой. Компьютер может сказать: *(а)* «вы сойдётесь, ждите примерно столько-то раундов»; *(б)* «вы не сойдётесь никогда, и вот минимальный набор убеждений-виновников»; *(в)* «на самом деле вы спорите о значении слова X — договоритесь о нём, и вы согласны», либо «нет, конфликт настоящий, вот формула, о которой вы реально расходитесь, и вот прейскурант минимальных уступок»; *(г)* «а вот стоит ли вам вообще тратить время на этот спор —

посчитаем». Применимо там, где согласованный словарь уже существует: переговоры, договоры, стратегические сессии, консалтинг, и даже споры между ИИ-агентами.